

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



پروژه درس داده کاوی  
تئوری

استاد محترم درس  
جناب آقای دکتر پاینده

دانشجو  
آیدا اعلا بیکی



## آمیزه‌ای متناهی از مدل‌های آماری

در آمار یک مدل آمیزه‌ای در واقع یک مدل احتمالاتی برای نمایش وجود زیرجامعه در داخل یک جامعه‌ی کلی است، در شرایطی که هیچ کدام از مشاهدات نشانی دقیق دال بر تعلق به هر یک از زیرجامعه‌ها ندارند. به طور کلی هر آمیزه‌ای متناهی از مدل‌های آماری یک توزیع آمیزه‌ای است که به شکلی دقیق توزیع جامعه‌ی تحت پوشش خود را توضیح می‌دهد.

برخی از روش‌های اجرای مدل‌های آمیزه‌ای شامل مراحل است که هویت‌های زیر جمعیتی را براساس مشاهدات فردی (یا وزنه‌های مربوط به چنین زیر جمعیتی) نسبت می‌دهد، که در این صورت می‌توان این موارد را به عنوان انواع روش‌های یادگیری یا خوشه‌بندی بدون نظارت در نظر گرفت. با این وجود، تمام مراحل استنتاج شامل چنین مراحل نیست. مدل‌های آمیزه‌ای را نباید با مدل‌هایی برای داده‌های ترکیبی اشتباه گرفت، یعنی داده‌هایی که اجزای آنها محدود به یک مقدار ثابت هستند (1، 100٪ و غیره). با این حال، مدل‌های ترکیبی را می‌توان مدل‌های آمیزه‌ای دانست که در آن اعضای جامعه بصورت تصادفی نمونه برداری می‌شوند. در مقابل، مدل‌های آمیزه‌ای را می‌توان مدل‌های ترکیبی دانست که در آن کل احتمال پوشش داده شده توسط جامعه با توجه به ضریب نرمال سازی 1 شده است. مدل‌های داده‌های ترکیبی بخصوص زمانی که اندازه‌گیری‌های مکرر در یک سری از واحدهای آماری (مطالعه طولی) انجام یا جایی که اندازه‌گیری‌ها بر روی خوشه‌ای از واحدهای آماری مرتبط انجام می‌شود، بسیار مفید هستند. در ادامه تعریفی از مدل آمیزه‌ای متناهی ارائه می‌دهیم.

---

تعریف 9-1: فرض کنید  $Y_1, \dots, Y_n$  یک نمونه‌ی تصادفی به اندازه‌ی  $n$  باشد، به‌طوری که  $Y_j$  یک بردار تصادفی  $p$  بعدی با تابع چگالی احتمال  $f(y_j; \theta_i)$  برای  $(i = 1, \dots, g)$  روی فضای  $R^p$  است. اگر  $f_i(y_j; \theta_i)$  تابع چگالی  $j$  امین متغیر در  $i$  امین جامعه باشد، در آن صورت آمیزه‌ای متناهی از توابع چگالی متغیر تصادفی  $Y$  بدین صورت نوشته می‌شود:

$$f(y_j, \psi) = \sum_{i=1}^g \pi_i f_i(y_j; \theta_i)$$

$\psi$  برداری شامل تمام پارامترهای نامعلوم در مدل آمیزه‌ای است و به‌صورت  $\psi = (\pi_1, \dots, \pi_{g-1}, \xi^T)^T$  تعریف می‌شود.  $\pi_1, \dots, \pi_g$  کمیت‌هایی نامنفی هستند که به‌عنوان وزن‌ها نامیده می‌شوند و مقادیری را بین صفر و یک اختیار می‌کنند به‌طوری که

$$\sum_{i=1}^g \pi_i = 1$$


---

## مثال‌هایی از کاربرد توزیع‌های آمیخته

### • یک مدل مالی

بازده مالی اغلب در شرایط عادی و در زمان بحران متفاوت رفتار می‌کند. یک مدل آمیزه‌ای برای داده‌های بازده مالی منطقی به نظر می‌رسد. گاهی اوقات مدل مورد استفاده یک مدل پرش-انتشار یا به عنوان ترکیبی از دو توزیع نرمال است.

### • قیمت خانه

فرض کنید قیمت  $N$  خانه را مشاهده کرده‌ایم. قطعا انواع مختلف خانه در محله‌های مختلف قیمت‌های متفاوتی با یکدیگر خواهند داشت، اما قیمت یک خانه مشخص در یک محله مشخص به میانگین خوشه‌ی مربوط به محله‌ی خود نزدیک است. یک مدل ممکن برای این قیمت‌ها می‌تواند آمیزه‌ای از  $K$  توزیع باشد که هر مولفه می‌تواند یک توزیع نرمال با میانگین و واریانس مجهول باشد. هر مولفه قیمت خانه را در یک محله‌ی مشخص مدل می‌کند.

برآزش این مدل به داده‌ها با استفاده از روش EM می‌تواند پراکندگی قیمت در هر محله را مشخص کند. (توجه داشته باشید که برای شاخص‌هایی مانند قیمت یا درآمد که قطعا مثبت هستند و تمایل به رشد به صورت نمایی دارند، توزیع لگ-نرمال ممکن است انتخاب مناسب‌تری نسبت به توزیع نرمال باشد.)

### • تشخیص دست خط

مثال زیر از کتاب کریستوفر م. بیشوپ، شناخت الگو و یادگیری ماشین انتخاب شده است. فرض کنید به ما یک تصویر  $N \times N$  پیکسل سیاه سفید داده شده است که می‌دانیم یک اسکن از دست نوشته‌ی فردی است که قطعا یکی از اعداد 0 تا 9 می‌باشد، اما ما نمی‌دانیم که کدام یک از اعداد نوشته شده است. در این جا ما می‌توانیم یک مدل آمیزه‌ای با  $K=10$  مولفه در نظر بگیریم که هر مولفه یک بردار به اندازه‌ی  $N^2$  از توزیع‌های دو جمله‌ای می‌باشد (به ازای هر پیکسل). چنین مدلی می‌تواند توسط الگوریتم EM بر روی تعدادی دست‌نوشته‌ی بدون برچسب آموزش داده شود، سپس مدل قادر است که دست‌نوشته‌ها را با توجه به عددی که بر روی آن‌ها نوشته شده است خوشه‌بندی کند. همین مدل می‌تواند پس از آموزش برای دسته‌بندی دست‌نوشته‌های جدید استفاده شود.

✓ در بسیاری از مسئله‌های برآورد پارامترهای مدل آماری، به شکلی از تابع درستمایی برخوردار می‌کنیم که امکان پیشینه‌سازی آن به روش تحلیلی وجود ندارد. تعداد پارامترهای زیاد، محاسبات تحلیلی را افزایش می‌دهند. در چنین مواقعی با اضافه کردن متغیر پنهان (که البته مقدار آن نیز مشاهده نشده) ممکن است مدل تابع درستمایی، ساده‌تر شده و امکان محاسبات عددی برای پیشینه‌سازی را فراهم آورد. این تکنیک در به‌دست آوردن برآورد ML پارامترهای یک مدل آمیزه‌ای استفاده می‌شود.

الگوریتم EM یکی از روش‌هایی است که براساس وجود متغیر پنهان امکان برآورد پارامترهای مدل آماری را میسر می‌سازد. این الگوریتم اولین بار توسط «آرتور دمپستر» دانشمند آمار و همکارانش در مقاله‌ای با عنوان «حداکثر درستمایی برای داده‌های ناکامل بر مبنای الگوریتم EM» که در سال 1977 منتشر شد معرفی گردید.

## 6-1- تقریب تغییرات

### مقدمه

تحلیل دقیق بیزی داده‌های آمیزه‌ای از نقطه نظر محاسباتی بسیار پیچیده است، زیرا تابع درستنمایی دارای فرمی گسترده با تعداد زیادی مولفه است، در عمل استفاده از نوعی تقریب برای استنباط اجتناب‌ناپذیر است و در طول سالیان وقت و انرژی زیادی در جهت طراحی روش‌هایی برای تقریب توزیع پسین و پیشگو صرف شده است.

به طور معمول اینگونه استباطها بر مبنای روش‌های MCMC صورت می‌گیرد، و درواقع استنباط‌های مبتنی بر MCMC تا حد بسیار قابل قبولی صحیح هستند به عبارتی توزیع تجربی به دست آمده از این روش تا حد بسیار زیادی به توزیع واقعی نزدیک است؛ با این حال در عمل مشکلات فراوانی برای پیاده‌سازی این روش وجود دارد مخصوصاً زمانی که تعداد مشاهدات بسیار زیاد بوده و پارامترهای زیادی وجود داشته باشد.

در نتیجه به خاطر فضای ذخیره‌سازی مورد نیاز، زمان مورد نیاز برای محاسبات و مسائلی از این دست این روش مورد قبول واقع نمی‌شود.

مسائل مطرح شده باعث طراحی روش‌های دیگری برای شبیه‌سازی توابع چگالی پیچیده گردید که از این روش‌ها می‌توان به دو روش

1. تقریب تغییرات

2. انتشار-امید

اشاره کرد.

این نکته را مدنظر داشته باشید که نتیجه‌ی روش تقریب تغییرات دقیق نیست مگر اینکه  $n \rightarrow \infty$  اما به دلیل برخی از ویژگی‌های مجانبی بسیار محبوب است.

### مقدمه‌ای بر تقریب تغییرات

ایده‌ی اولیه‌ی این روش بسیار منطقی و طبیعی است، به عبارتی ایده اولیه یافتن بهترین توزیع تقریبی ( $q$ ) برای تابع چگالی هدف ( $p$ ) است که در این جا معیار بهترین بودن بر اساس یک فاصله بین  $p$  و  $q$  است. معیارهای زیادی برای سنجش این فاصله وجود دارد اما یکی از مهم‌ترین این معیارها، معیار کولبک-لیبلر یا آنتروپی نسبی می‌باشد که به صورت زیر تعریف می‌شود.

$$KL(q, p) = \int q \log(q / p) \quad (1)$$

نکته: می‌توان به راحتی نشان داد که

$$KL(p \parallel q) = -H(p) + H(p, q)$$

که در آن  $H(\cdot)$  آنتروپی و  $H(\cdot, \cdot)$  آنتروپی متقابل است.

واضح است که معیار (1) متقارن نیست در نتیجه نمی تواند یک متر باشد، اما این معیار نامنفی است و صفر است اگر و تنها اگر  $p=q$  پس هر چه مقدار معیار (1) بیشتر باشد فاصله ی بین توزیع تقریبی ( $q$ ) و توزیع دقیق ( $p$ ) بیشتر است. بدون اعمال هیچ گونه محدودیتی بر روی  $q$  واضح است که بهترین انتخاب برای  $q$  خود  $p$  می باشد، اما در عمل تابع چگالی  $p$  بیش از حد پیچیده است در نتیجه محدودیت هایی بر روی  $q$  اعمال می شود که عمل یافتن تقریب را تسهیل کند اما  $q$  را اندکی از  $p$  دور می کند. در بسیاری از کاربردها  $P_D = P(.|D)$  است که در واقع تابع چگالی شرطی مقادیر مشاهده نشده ( $u$ ) به شرط داده های مشاهده شده ( $D$ ) است و  $q$  به شکلی انتخاب می شود که مقدار زیر را با توجه به محدودیت های اعمال شده بر روی  $q$ ، حداقل کند.

$$KL(q, p_D) = \int q(u) \log[q(u) / p(u|D)] du$$

می توان برای تابع درستنمایی نوع دوم ( $P(D)$ ) با توجه به رابطه ی بالا یک کران پایین یافت، که به صورت زیر می باشد.

$$\log p(D) = \int q(u) \log[p(D, u) / q(u)] du + KL(q, p_D)$$

از آنجایی که معیار  $KL$  نامنفی است در نتیجه می توان نوشت

$$\log p(D) \geq \int q(u) \log[p(D, u) / q(u)] du = F(q) \quad (2)$$

می توان نشان داد  $q$  ای که مقدار  $KL(q, p_D)$  را حداقل می کند بهترین کران پایین را برای  $\log(P(D))$  فراهم می کند. عبارت سمت راست رابطه ی (2) در فیزیک آماری به عنوان انرژی آزاد توزیع  $q$  شناخته می شود.

بهترین  $q$ ، انرژی آزاد را حداکثر می کند و همین موضوع روش تقریب تغییرات را ممکن می کند.

در دیدگاه فراوانی گرانایج بالا اجازه می دهد که یک تابع درستنمایی را در حضور داده ی گمشده تقریب بزنیم. در اینجا  $u$  نشان دهنده ی داده گمشده و  $(D, u)$  مجموعه ی کامل داده ها می باشد. در نتیجه  $q$  توزیع شرطی داده های گمشده به شرط مقادیر مشاهده است، و (2) یک کران پایین برای میزان درستنمایی لگاریتم داده های مشاهده شده فراهم می کند.

در دیدگاه بیزی مقادیر مشاهده نشده شامل پارامترها و داده های گمشده است. در این صورت اگر  $\theta$  بردار تمام پارامترهای مدل باشد در این صورت داریم  $u = (\theta, z)$  که در آن  $z$  نشان دهنده ی مقادیر گمشده می باشد که در بحث توزیع های آمیزه ای  $z$ ، وزن های آمیزش می باشد. در نتیجه  $q$  در اینجا  $P(\theta, z|D)$  می باشد، که در واقع توزیع پسین پارامترها و وزن های آمیزش است و (2) یک کران پایین برای لگاریتم تابع درستنمایی حاشیه ای مشاهدات ارائه می کند. این تابع به عنوان تابع درستنمایی نوع دوم شناخته می شود.

تابع درستنمایی نوع دوم نقش مهمی در بحث فاکتور بیزی برای مقایسه مدل ها دارد. همان طور که گفته شد باید یک سری از محدودیت ها بر روی  $q$  اعمال شود، یکی از محدودیت های استاندارد به صورت زیر است.

$$q(\theta, z) = q^{(0)}(\theta)q^{(z)}(z)$$

فرض کرده ایم که وزن ها و پارامترها دارای توزیع مستقل هستند. واضح است که این فرض، یک فرضیه ی پایه ای است. توجه کنید که در اینجا یک داد و ستد بین دقت و راحتی محاسبات برقرار است و باید به شکلی دقیق بررسی شود که افزایش سرعت محاسبات تا چه حد باعث کاهش دقت می شود.

در اینجا  $q^{(0)}(\theta)$  نشان دهنده ی تقریب تغییراتی توزیع پسین  $P(\theta|D)$  است.

باتوجه به رابطه (2) داریم

$$\begin{aligned}\log p(D) &\geq \int \sum_z q^{(0)}(\theta) q^{(z)}(z) \log [p(D, z, \theta) / q^{(0)}(\theta) q^{(z)}(z)] d\theta \\ &= F(q^{(0)}, q^{(z)})\end{aligned}\quad (3)$$

که می توان رابطه (3) را به شکل زیر بازنویسی کرد

$$\log p(D) \geq \int q^{(0)}(\theta) \left\{ \sum_z q^{(z)}(z) \log [p(D, z | \theta) / q^{(z)}(z)] + \log [p(\theta) / q^{(0)}(\theta)] \right\} d\theta$$

می دانیم که بهترین انتخاب برای  $q^{(0)}$  و  $q^{(z)}$  سمت راست رابطه ی (3) را حداکثر می کند. پس باید دو عبارت زیر را حداکثر کنند.

$$\int q^{(0)}(\theta) \log \left( \frac{\exp \left\{ \sum_z q^{(z)}(z) \log [p(D, z, \theta)] \right\}}{q^{(0)}(\theta)} \right) d\theta \quad (4)$$

$$\sum_z q^{(z)}(z) \log \left( \frac{\exp \left\{ \int q^{(0)}(\theta) \log [p(D, z, \theta)] d\theta \right\}}{q^{(z)}(z)} \right) \quad (5)$$

می توان دید که  $q^{(0)}$  و  $q^{(z)}$  باید در روابط زیر صدق کنند.

$$q^{(0)}(\theta) \propto \exp \left\{ \sum_z q^{(z)}(z) \log [p(D, z, \theta)] \right\} \quad (6)$$

$$q^{(z)}(z) \propto \exp \left\{ \int q^{(0)}(\theta) \log [p(D, z, \theta)] d\theta \right\} \quad (7)$$

حل صریح این دو معادله ممکن نیست؛ اما با نوشتن معادلات در فرم خلاصه شده  $q^{(z)} = T^{(z)}(q^{(0)})$ ،  $q^{(0)} = T^{(0)}(q^{(z)})$ ، می توان یک الگوریتم تکرارشونده را نوشت، ابتدا یک نقطه ی اولیه به صورت  $q^{(z)} = q^{(z)(0)}$  را انتخاب می کنیم حال برای  $m=0,1,\dots$  داریم

$$q^{(z)(m+1)} = T^{(z)}(q^{(0)(m+1)})$$

$$q^{(0)(m+1)} = T^{(0)}(q^{(z)(m)})$$

ساختار این الگوریتم به شکلی است که به ازای  $F(q^{(0)}, q^{(z)})$  (انرژی آزاد) در رابطه ی (3) داریم.

$$F(q^{(0)(m)}, q^{(z)(m)}) \leq F(q^{(0)(m+1)}, q^{(z)(m)}) \leq F(q^{(0)(m+1)}, q^{(z)(m+1)}) \quad (8)$$

پس انرژی آزاد به صورت یکنوا افزایش می یابد و به بهترین کران پایین  $\log P(D)$  نزدیک می شود. در نتیجه دنباله تولید شده همگراست، اگرچه تابع هدف دارای تعدادی حداکثر محلی است و مسئله ی وجود حداکثرهای محلی مشکلی شایع است. در ادامه یک مثال از کاربرد این روش در بررسی مدل های آمیزه ای ارائه می دهیم.

فرض کنید  $D = \{y_1, \dots, y_n\}$  نمونه ای تصادفی از توزیع آمیزه ای زیر باشد.

$$p(y | \theta) = \sum_{j=1}^k \lambda_j f_j(y)$$

که در آن  $f_j$  کاملاً شناخته شده است پس بردار پارامترهای  $\theta$  تنها شامل  $\lambda_j$  ها می باشد. در این مثال داریم



$$p(D, \mathbf{z}, \theta) = \prod_{i=1}^n \prod_{j=1}^k \left( \lambda_j^{z_{ij}} f_{ij}^{z_{ij}} \right) p(\theta)$$

که در آن  $z_{ij} = 1$  اگر و تنها اگر مشاهده‌ی  $i$ ام از مولفه‌ی  $j$ ام باشد،  $f_{ij} = f_j(y_i)$  و  $P(\theta)$  توزیع پیشین برای  $\theta$  است؛ اگر ما فرض کنیم  $\text{Dir}(a^{(0)})$  توزیع پیشین  $\theta$  باشد بنابراین

$$p(D, \mathbf{z}, \theta) \propto \prod_{j=1}^k \lambda_j^{\sum_i z_{ij} + a_j^{(0)} - 1}$$

بنابراین

$$\sum_{\mathbf{z}} q^{(z)}(\mathbf{z}) \log[p(D, \mathbf{z}, \theta)] = \sum_{j=1}^k \left( \sum_i q_{ij}^{(z)} + a_j^{(0)} - 1 \right) \log \lambda_j + \text{const}$$

که در آن  $\text{const}$  مستقل از  $\theta$  و  $q_{ij}^{(z)}$  احتمال حاشیه‌ای برای  $z_{ij} = 1$  طبق توزیع  $q^{(z)}(z)$  می‌باشد.

از (8) داریم که بهینه‌ترین توزیع برای  $q^{(0)}(\theta)$  توزیع  $\text{Dir}(a)$  با پارامتر  $a_j = \sum_i q_{ij}^{(z)} + a_j^{(0)}$ ،  $i = 1, \dots, k$  می‌باشد؛ در ادامه توزیع بهینه برای  $q^{(z)}(z)$  را بر حسب تابعی از  $q^{(0)}(\theta)$  به دست می‌آوریم؛ داریم

$$\int q^{(0)}(\theta) \log[p(D, \mathbf{z}, \theta)] d\theta = \sum_{i=1}^n \sum_{j=1}^k z_{ij} \left[ \log(\phi_j^{(q)}) + \log f_{ij} \right] + \text{const}$$

که در آن داریم

$$\phi_j^{(q)} = \exp \left[ E_{q^{(0)}} \log(\lambda_j) \right]$$

و در اینجا  $\text{const}$  مستقل از  $\{z_{ij}\}$  می‌باشد.

اگر عبارت حاصل شده را در (7) جاگذاری کنیم مشاهده می‌کنیم که توزیع بهینه برای  $q^{(z)}(z)$  به شکل یک فرم ضربی درمی‌آید که در آن هر مشاهده برای خود مضربی دارد و مضارب بهینه برای توزیع بهینه به شکل زیر هستند

$$q_{ij}^{(z)} \propto f_{ij} \phi_j^{(q)}$$

و داریم  $\sum_j q_{ij}^{(z)} = 1$ ،  $\forall i, j = 1, \dots, k$ ، از خواص توزیع دیریکله داریم  $\Psi(a_j) - \Psi(a) = E_{q^{(0)}} [\log \lambda_j]$  که در آن  $\Psi$  نشان‌دهنده‌ی تابع گاما است و  $a = \sum_j a_j$ ؛ بنابراین داریم

$$q_{ij}^{(z)} = f_{ij} \exp \left[ \Psi(a_j) - \Psi(a) \right] / \sum_{r=1}^k f_{ir} \exp \left[ \Psi(a_r) - \Psi(a) \right]$$

همان‌طور که می‌شد حدس زد معادلات کاملاً تحت‌تاثیر  $\{a_j\}$  هستند و  $\{q_{ij}^{(z)}\}$  به صورت صریح قابل محاسبه نیست اما الگوریتم تکرار شونده به صورت زیر مسئله را حل می‌کند.

فرض کنید به عنوان نقطه‌ی ابتدایی،  $q_{ij}^{(z)(0)} = f_{ij} a_j^{(0)} / \left( \sum_{r=1}^k f_{ir} a_r^{(0)} \right)$ ، را انتخاب کنیم، در نتیجه گام‌های زیر را برای

$m = 0, 1, \dots$  داریم

گام 1: برای  $j = 1, \dots, k$  مقدار زیر را محاسبه کن

$$a_j^{(m+1)} = \sum_i q_{ij}^{(z)(m)} + a_j^{(0)}$$

گام 2: برای  $i = 1, \dots, n$  و  $j = 1, 2$  مقدار زیر را محاسبه می کنیم.

$q_{ij}^{(z)(m+1)} = f_{ij} \exp \left[ \Psi(a_j^{(m+1)}) - \Psi(a_i^{(m+1)}) \right] / \sum_{r=1}^k f_{ir} \exp \left[ \Psi(a_r^{(m+1)}) - \Psi(a_i^{(m+1)}) \right]$  به این نکته جالب توجه کنید که گام 1 الگوریتم مشابه گام M و گام 2 مشابه گام E الگوریتم EM است، تفاوت عمده‌ی دو الگوریتم جایگزینی  $q_{ij}^{(z)(m)}$  به جای  $z_{ij}^{(m)}$  است.

در برخی از کتب به این الگوریتم EM تغییراتی گفته می شود.

### نتایج مجانبی

تقریب تغییرات بیزی برای بسیاری از مسائل طراحی شده است، اما مزایای واقعیانه‌ی آن باید براساس مبانی تئوری مورد بررسی قرارگیرد.

آنیاس (1999، 2000) و پنی و رابرتز (2000) ادعا کردند که در مسائل خاص، برآورد بیزی تغییراتی، بر مبنای میانگین پسین تغییراتی، در بزرگ نمونه به برآوردگر حداکثر درستنمایی میل می کند، اما هیچ اثبات دقیقی ارائه نشد. اخیراً تحقیقات بیشتری در این زمینه انجام شد، وانگ و تیتزینگتون (2004) ثابت کردند در آمیزش  $k$  توزیع شناخته شده، برای حالتی که توزیع پسین وزن‌ها دیریکله باشد، برآورد بیزی تغییراتی (میانگین توزیع پسین تغییراتی) برای وزن‌های آمیزش به صورت مجانبی برابر با برآورد حداکثر درستنمایی می شود.

وانگ و تیتزینگتون (2005) اثبات قبلی خود را بهبود بخشیده و ثابت کردند توزیع پسین مجانبی تغییراتی پارامترها، نرمال است.

در نتیجه می توان گفت در عموم مواقع تقریب تغییراتی به صورت مجانبی رفتار معقولی دارد، اگرچه مقالاتی که به بررسی رفتار مجانبی ماتریس واریانس-کوواریانس پرداخته است نشان داده است که برآورد حاصل از طریق روش تقریب تغییرات "بسیار کوچک تر" از برآورد حاصل از طریق روش حداکثر درستنمایی است؛ به عنوان یک نتیجه از این موضوع داریم که برآورد فاصله‌ای حاصل از روش تقریب تغییرات برای پارامترها به شکل غیرواقعی طول کمی خواهد داشت.

به عنوان مثالی از خواص مجانبی، برای  $k=2$  (توزیع آمیخته دو توزیع) واریانس توزیع تقریبی تغییراتی برای پارامتر وزن  $\lambda$  برابر است با  $\lambda(1-\lambda)/n$  که دقیقاً برابر واریانس حاصل در روش حداکثر درستنمایی بر مبنای داده‌های کامل است.

وانگ و تیتزینگتون (2004) یک خانواده از توزیع‌های نمایی با مقادیر گم‌شده را در نظر گرفتند و همگرایی الگوریتم تکراری برای محاسبه‌ی تقریب تغییراتی را اثبات کردند؛ همچنین آن‌ها ثابت کردند که توزیع مجانبی برآوردگرها نرمال است.

مشاهدات نشان داده است در بحث زنجیرهای مارکوف پنهان استفاده از فرم کاملاً ضربی  $q^{(z)}$  نتایج مطلوبی برای تقریب تغییراتی حاصل نمی کند.